

Evaluación Parcial N°1

Asistente inteligente con LLM y RAG para apoyo a la gestión y diagnóstico de reparaciones en redes FTTH

Estudiante: Miguel Zavala Vásquez

Asignatura: ISY0101

Año: 2026

1. Caso organizacional y problemática

El proyecto aborda el apoyo al diagnóstico de incidencias en redes FTTH. En la operación real, una nueva incidencia comienza normalmente con la dirección afectada. A partir de ella se requiere identificar la infraestructura asociada —OLT, tarjeta, puerto, nodo, NAP, anillo y sitio técnico— para determinar desde dónde iniciar las revisiones.

Una vez identificada la infraestructura, el supervisor se dirige al sitio técnico y realiza mediciones desde el ODF correspondiente, utilizando OTDR para estimar eventos y distancias en la fibra. Con el nodo identificado se consulta además la planimetría de la red, lo que permite orientar a las brigadas hacia un posible sector de falla. Los registros históricos muestran precisamente este tipo de trabajo: mediciones, trazas, búsqueda mediante planos, reparación y validación del servicio.

El problema abordado por este prototipo aparece cuando se necesita consultar rápidamente qué ocurrió en incidencias anteriores similares y qué verificaciones o acciones fueron realizadas. La información histórica existe, pero su revisión manual puede ser lenta y dispersa. Por ello se propone utilizar RAG para recuperar antecedentes técnicamente relacionados y entregarlos a un LLM como contexto, de modo que genere una orientación trazable. La herramienta apoya al supervisor y al técnico; no reemplaza la medición, el diagnóstico ni la decisión en terreno.

Objetivo general

Desarrollar un prototipo de asistente inteligente basado en LLM y RAG que apoye la gestión y el diagnóstico inicial de incidencias FTTH mediante la recuperación de antecedentes históricos y documentación técnica externa, entregando casos similares, verificaciones previas y orientación técnica con trazabilidad.

Objetivos específicos

- Recuperar antecedentes históricos FTTH semánticamente relacionados con una nueva incidencia mediante embeddings y una base vectorial.
- Integrar fuentes internas y documentación técnica externa, identificando su procedencia mediante metadatos.
- Generar orientación técnica trazable con un LLM, utilizando el contexto recuperado y manteniendo la decisión final en el personal técnico.

2. Datos utilizados y preparación de la información

La base de trabajo contiene 1411 registros FTTH anonimizados. Para el prototipo se seleccionaron cuatro categorías relacionadas con fallas de interés operacional, totalizando 505 casos disponibles: Atenuación (167), Filamento Atenuado (75), Filamento cortado (180) y Caja CTO en mal estado (83).

Para mantener un prototipo acotado y equilibrado se utilizaron 80 documentos: 20 casos por categoría. Cada registro se transformó en un documento de conocimiento con Caso_ID, tipo de red, motivo registrado, distancia aproximada, acción de reparación y uso de materiales. Los identificadores FTTH-XXXX permiten mantener trazabilidad sin exponer nombres de clientes, direcciones ni datos personales.

Categoría	Disponibles	Usados en MVP
Atenuación	167	20
Filamento Atenuado	75	20
Filamento cortado	180	20
Caja CTO en mal estado	83	20




Figura 1. Distribución de los 505 casos FTTH disponibles en las cuatro categorías seleccionadas.

Fuente externa

Como conocimiento externo se incorporó una síntesis técnica identificada como ITU-G984.1, correspondiente a la recomendación ITU-T G.984.1 sobre características generales de GPON. En Chroma se etiquetó con el metadato tipo_fuente = fuente_externa, mientras que los 80 históricos se etiquetaron como fuente_interna.

3. Diseño e implementación del pipeline RAG

El flujo implementado en Google Colab utiliza GoogleGenerativeAIEmbeddings con el modelo gemini-embedding-001. En la prueba realizada, cada consulta generó un vector de 3.072 dimensiones. Los documentos se indexaron en Chroma, permitiendo realizar búsquedas por similitud semántica.

- Entrada: descripción de una nueva incidencia FTTH.
- Embedding: transformación de la consulta a representación vectorial.
- Retrieval: búsqueda de antecedentes internos relevantes y recuperación controlada de documentación externa.
- Contexto: unión de los documentos recuperados.
- Generation: envío del contexto y un prompt con reglas a Gemini.
- Salida: análisis, antecedentes, orientación, verificaciones sugeridas y trazabilidad.

Prompt y control de contexto

El prompt instruye al modelo a no inventar mediciones, causas ni reparaciones; diferenciar fuentes internas y externas; no presentar una causa posible como diagnóstico confirmado; proponer verificaciones solo desde el contexto recuperado; identificar Caso_ID y referencia externa; y mantener la decisión final en el personal técnico.

El diseño mantiene el uso de la IA como apoyo al análisis. Las reglas del prompt y la trazabilidad permiten revisar de dónde proviene la información utilizada antes de considerar una orientación técnica.

4. Arquitectura de la solución

1. Entrada	Nueva incidencia FTTH descrita por el supervisor.
2. Representación semántica	gemini-embedding-001 transforma la consulta y los documentos en vectores.
3. Recuperación en Chroma	Se recuperan 3 casos históricos internos y 1 documento técnico externo mediante metadatos.
4. Generación con Gemini	El LLM recibe únicamente el contexto recuperado y las reglas del prompt.
5. Salida trazable	Análisis, antecedentes, posible orientación, verificaciones sugeridas y fuentes utilizadas.

Fuentes de conocimiento: 80 casos históricos FTTH anonimizados (fuente_interna) + ITU-T G.984.1 (fuente_externa). Cada caso histórico se utiliza como un documento del prototipo; no se implementó división automática en chunks.



Figura 2. Arquitectura de la solución RAG para apoyo al diagnóstico FTTH.

La arquitectura separa el conocimiento interno de la documentación externa y los integra durante la recuperación. Chroma actúa como base vectorial; el modelo de embeddings permite comparar semánticamente la nueva incidencia con los documentos; y Gemini recibe únicamente el contexto seleccionado junto con las reglas del prompt.


Alcance actual: el prototipo comienza desde una descripción técnica de la incidencia. La identificación automática de OLT, tarjeta, puerto, nodo, NAP, anillo y sitio técnico a partir de una dirección queda planteada como evolución futura y no se presenta como funcionalidad implementada.

Criterio técnico aplicado: desde mi experiencia operacional, disponer de antecedentes históricos similares antes de atender una falla puede reducir el tiempo destinado a búsquedas manuales y entregar una referencia inicial de lo que conviene revisar. El sistema se plantea como apoyo previo a la toma de decisiones y no como reemplazo del criterio técnico. Además, la identificación de la procedencia de cada antecedente permite distinguir si la información corresponde a un caso histórico interno o a documentación técnica externa.

5. Pruebas y resultados

Se realizaron pruebas controladas para comprobar la coherencia entre la consulta, los documentos recuperados y la respuesta generada. En una incidencia con degradación cercana a -25 dBm se recuperaron antecedentes de atenuación y filamento atenuado. En una segunda prueba, asociada a daño físico de una CTO, los tres resultados recuperados correspondieron a la categoría “Caja CTO en mal estado” (FTTH-0084, FTTH-0405 y FTTH-0391).

Posteriormente se verificó la recuperación de la fuente externa: ante una consulta conceptual sobre arquitectura GPON, ITU-G984.1 apareció como primer resultado. Finalmente se aplicó recuperación diferenciada, obteniendo tres fuentes internas (FTTH-0437, FTTH-0134 y FTTH-0113) y una fuente externa (ITU-G984.1), que fueron unidas en un contexto de cuatro documentos para la generación final.



```
filter(["tipo_fuente": "fuente_interna"])


print("RECUPERACIÓN RAG: FUENTES INTERNAS + EXTERNAS")
print("-" * 45)

print("FUENTES INTERNAS RECUPERADAS:")
for doc in resultados_internos:
    print(
        "doc.metadata.get('caso_id'),\n",
        "doc.metadata.get('motivo'),\n",
        "doc.metadata.get('tipo_fuente')\n"
    )

print("FUENTE EXTERNA RECUPERADA:")
for doc in resultados_externos:
    print(
        "doc.metadata.get('caso_id'),\n",
        "doc.metadata.get('motivo'),\n",
        "doc.metadata.get('tipo_fuente')\n"
    )

=====
RECUPERACIÓN RAG: FUENTES INTERNAS + EXTERNAS
=====
FUENTES INTERNAS RECUPERADAS:
- FTTH-0437 | Filamento Atenuado | fuente_interna
- FTTH-0134 | Atenuación | fuente_interna
- FTTH-0113 | Atenuación | fuente_interna
FUENTE EXTERNA RECUPERADA:
- ITU-G984.1 | Documentación técnica GPON | fuente_externa
```

Figura 3. Recuperación diferenciada: 3 fuentes internas + 1 fuente externa.



```
respuesta_combinada = llm.invoke(prompt_combinado)
respuesta_combinada_limpia = obtener_texto_respuesta(
    respuesta_combinada
)

print("RESPUESTA FINAL RAG - FUENTES INTERNAS + EXTERNAS")
print("-" * 45)
print(respuesta_combinada_limpia)

=====
RESPUESTA FINAL RAG - FUENTES INTERNAS + EXTERNAS
=====
ANÁLISIS:
Se analiza una incidencia en red FTTH por degradación de potencia óptica. La evaluación requiere revisar los elementos pasivos de la red de distribución óptica y los puertos de interconexión en equipos centrales, considerando que la decisión final de la acción a ejecutar corresponde al personal técnico en terreno.

ANTECEDENTES INTERNOS:
- "Caso ID: FTTH-0437": Reportó "Filamento Atenuado" a una distancia aproximada de 150.0 metros. Se registraron potencias degradadas en MAP (-25 dBm) provenientes desde la OLT hacia el SP. Tras tomar una traza desde la NWP (que mostró 1 dB de atenuación) se realizó la limpieza de la fibra en los puertos ópticos (puerto de OLT, hub o NWP).
- "Caso ID: FTTH-0134": Reportó "Atenuación" (distancia 0.0 m). Aporta como antecedente la realización de mediciones de potencia en CTO y Budi para constatar si los niveles están dentro de parámetros.
- "Caso ID: FTTH-0113": Reportó "Atenuación" (distancia 0.0 m). Aporta como solución documentada la realización de limpieza en la NWP y en el hub para mejorar los niveles de potencia.

FUENTE EXTERNA:
- "ITU-G984.1": Define que las redes GPON son redes ópticas pasivas de acceso compuestas por OLT (Optical Line Termination), ONU/ONT (Optical Network Unit / Optical Network Termination) y la ODN (Optical Distribution Network), la cual es susceptible a degradación de potencia óptica.

POSIBLE ORIENTACIÓN:
Sin dar una confirmación de diagnóstico, la degradación de potencia óptica podría estar vinculada a:
- Acumulación de suciedad en conectores de fibra o en los puertos ópticos (puerto de OLT, hub o NWP).
- Eventos de pérdida o atenuación en el filamento óptico a lo largo de la ODN.
- Desviaciones en los niveles de potencia generados desde la OLT o medidos en elementos de paso (SP, Budi, CTO, NWP).

VERIFICACIONES SUGERIDAS:
1. Realizar mediciones de potencia en los distintos puntos de la ODN (CTO, Budi, NWP y SP) para determinar el punto exacto donde se genera la atenuación.
2. Verificar la potencia de salida directamente en el puerto de la OLT para descartar o detectar degradación desde el origen.
3. Ejecutar trazados ópticos (reflectometría/traza) desde la NWP hacia la red para identificar pérdidas localizadas en el filamento (evaluando tramos como los 150 metros indicados en históricos).
4. Proceder con la revisión y limpieza de conectores y puertos en los puntos correspondientes (puerto OLT, hub, NWP) si se identifican niveles fuera de parámetro.
*La decisión final de la acción a ejecutar corresponde al personal técnico en terreno.*

TRAZABILIDAD:
- "Fuentes Internas": Caso ID: FTTH-0437, Caso ID: FTTH-0134, Caso ID: FTTH-0113.
- "Fuente Externa": ITU-G984.1 (Recomendación ITU-T G.984.1).
```

Figura 4. Respuesta final con antecedentes internos, fuente externa y trazabilidad.

La salida final separó antecedentes internos y fuente externa, propuso verificaciones y declaró explícitamente las fuentes utilizadas. Esto permite mostrar la relación entre recuperación y respuesta, aspecto requerido en la presentación de la evaluación.

6. Limitaciones, proyección, uso de IA y referencias

Limitaciones observadas

- El MVP utiliza 80 históricos, por lo que no representa todavía toda la base disponible.
- La fuente externa se incorporó como un documento técnico resumido; una versión posterior debería ampliar y segmentar documentación oficial adicional.
- La recuperación por similitud no garantiza por sí sola que una búsqueda global incluya ambas procedencias; por ello el prototipo implementó recuperación diferenciada mediante metadatos.
- El sistema no localiza automáticamente la infraestructura desde una dirección ni reemplaza mediciones OTDR, planimetría o validación en terreno.
- La respuesta del LLM debe ser revisada por personal técnico, ya que un modelo generativo puede producir interpretaciones incorrectas si el contexto es insuficiente.

Proyección

Como evolución del prototipo se propone integrar inventario y datos de planta para que, a partir de la dirección o identificador del servicio, sea posible asociar OLT, tarjeta, puerto, nodo, NAP, anillo y sitio técnico antes de ejecutar el RAG. Esto conectaría la etapa de localización operacional con la recuperación de antecedentes históricos.

Declaración de uso de IA

Se utilizó IA generativa como apoyo para comprender conceptos, depurar código, estructurar el prototipo, revisar redacción y preparar material visual. Los resultados fueron comprobados mediante ejecuciones en Google Colab y contrastados con los registros utilizados. La interpretación del problema operacional, el criterio sobre su utilidad en el trabajo y la reflexión final corresponden a mi experiencia y aprendizaje durante el desarrollo de la asignatura.

Conclusión

Como conclusión de este trabajo, considero que lo aprendido durante este ramo ha sido muy importante, ya que antes de comenzar no manejaba conceptos relacionados con modelos de lenguaje, embeddings o RAG. A medida que fui desarrollando las actividades y este proyecto, pude comprender la utilidad que pueden tener estas herramientas cuando se implementan de manera adecuada. En particular, considero que un modelo como el desarrollado puede ser de gran ayuda como apoyo previo a la atención de una falla, facilitando la búsqueda de antecedentes históricos y entregando información que puede servir para orientar la toma de decisiones. Esto podría reducir el tiempo dedicado a buscar información manualmente y permitir que antecedentes de reparaciones anteriores sean considerados antes de comenzar una revisión, sin reemplazar el criterio ni la experiencia del personal técnico. Durante las clases hubo conceptos que inicialmente me costó comprender, pero al revisar nuevamente la información y aplicarla de manera práctica fui entendiendo mejor su funcionamiento. Por este motivo, me gustaría continuar desarrollando nuevos modelos y proyectos que me permitan seguir reforzando lo aprendido.

Referencias

International Telecommunication Union. (2008). ITU-T Recommendation G.984.1: Gigabit-capable passive optical networks (GPON): General characteristics.

Duoc UC. (2025). Evaluación Parcial N°1: Diseño de Solución con LLM y RAG. ISY0101 Ingeniería de Soluciones con Inteligencia Artificial.

Documentación técnica del prototipo: Google Colab, LangChain Google GenAI y Chroma.